Dokumentasi Proyek Web Scraping Berita

1. **Arsitektur Sistem**
   Aplikasi ini dirancang dengan struktur modular yang memisahkan fungsi antarmuka, manajemen proses, dan mesin ekstraksi data. Berikut adalah pembagian tugas setiap file:
   - main.py: Merupakan titik masuk utama (Entry Point) aplikasi yang berfungsi menginisialisasi seluruh sistem.
   - GUI.py: Menangani seluruh antarmuka pengguna, mulai dari input URL, pengaturan parameter scraping, hingga penampilan hasil pada tabel.
   - worker.py: Bertugas sebagai pengelola proses di latar belakang (Background Thread) agar aplikasi tetap responsif saat pengambilan data sedang berlangsung.
   - scraper.py: Merupakan inti dari sistem yang mengontrol Selenium untuk melakukan navigasi website, identifikasi link berita, dan ekstraksi konten.
   - utils.py: Menyediakan fungsi bantuan untuk pemrosesan teks dan manajemen penyimpanan data hasil scraping.
2. **Alur Kerja Aplikasi (Scraping Workflow)**
   - Input Pengguna: Pengguna memasukkan URL target (seperti iNews atau CNN) dan menentukan batasan jumlah berita yang akan diambil melalui antarmuka.
   - Identifikasi Tautan: Mesin scraper akan memproses halaman utama URL tersebut untuk mendeteksi tautan berita yang relevan berdasarkan pola struktur URL.
   - Ekstraksi Data Paralel: Sistem membuka tautan berita yang ditemukan secara bersamaan menggunakan ThreadPoolExecutor untuk meningkatkan efisiensi waktu pengambilan data.
   - Pengolahan Konten: Data berupa judul, tanggal, dan isi berita diekstrak dan divalidasi guna memastikan informasi yang didapat sesuai dengan kebutuhan.
   - Penyajian & Ekspor: Hasil akhir ditampilkan secara real-time pada tabel aplikasi dan dapat disimpan ke dalam format file eksternal (Excel/CSV).
3. **Fitur Utama**
   - Multithreading: Memungkinkan pengambilan data dalam jumlah banyak secara cepat tanpa menyebabkan aplikasi berhenti merespons (freeze).
   - Smart Link Filter: Logika penyaringan yang dapat membedakan antara artikel berita utama dengan tautan navigasi atau iklan.
   - Headless Mode: Kemampuan untuk menjalankan proses scraping di latar belakang tanpa memunculkan jendela browser di layar pengguna.
   - Modularitas: Kode disusun secara terpisah antar fungsi sehingga memudahkan proses pemeliharaan dan pengembangan lebih lanjut.
4. **Foto Program Berjalan**
   - **Tampilan Setelah Scraping**

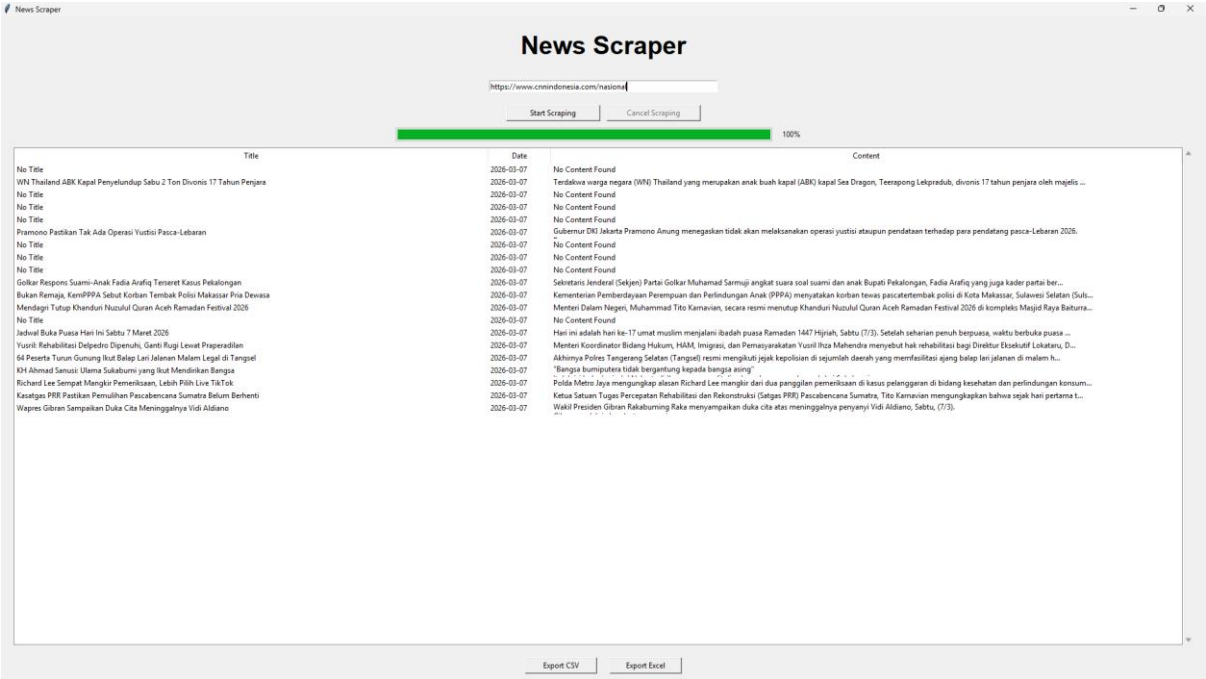

- **Tampilan Export Excel**

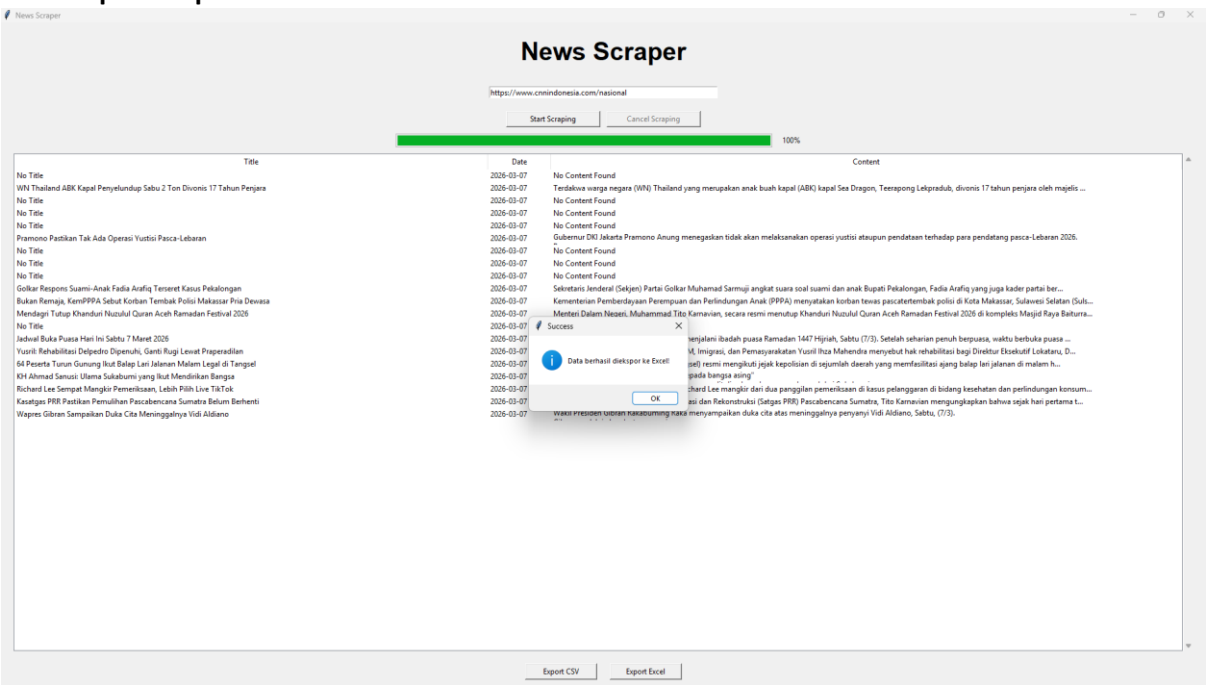

-Tampilan Export CSV

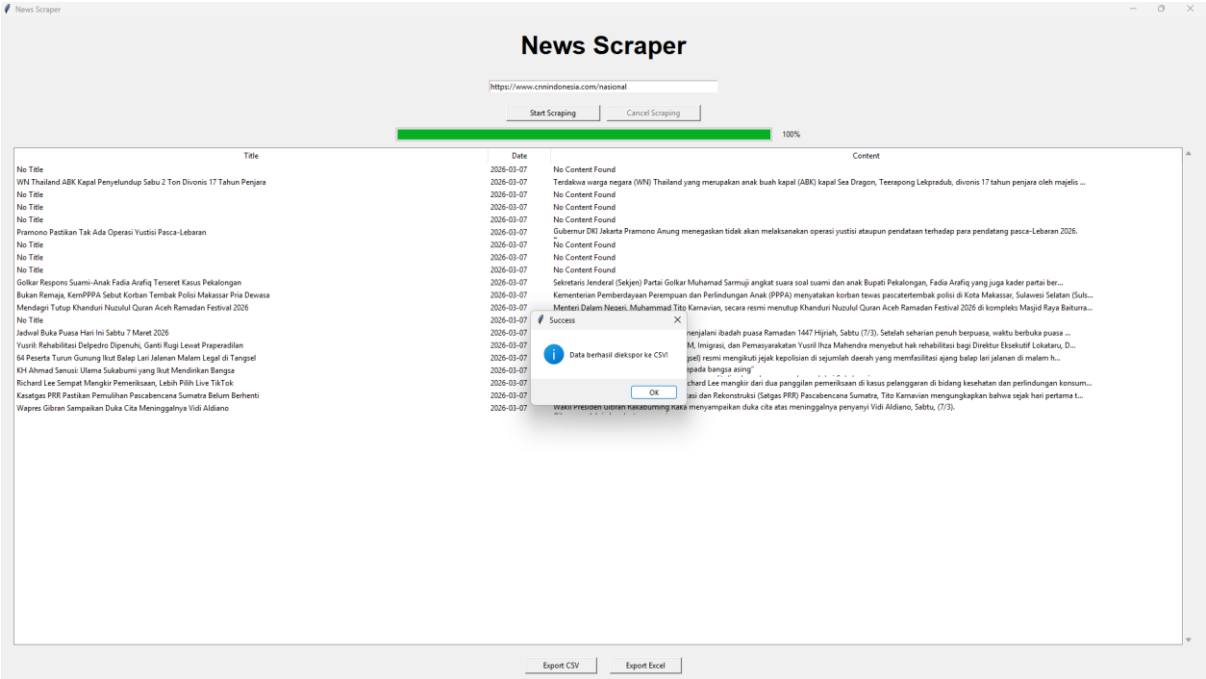
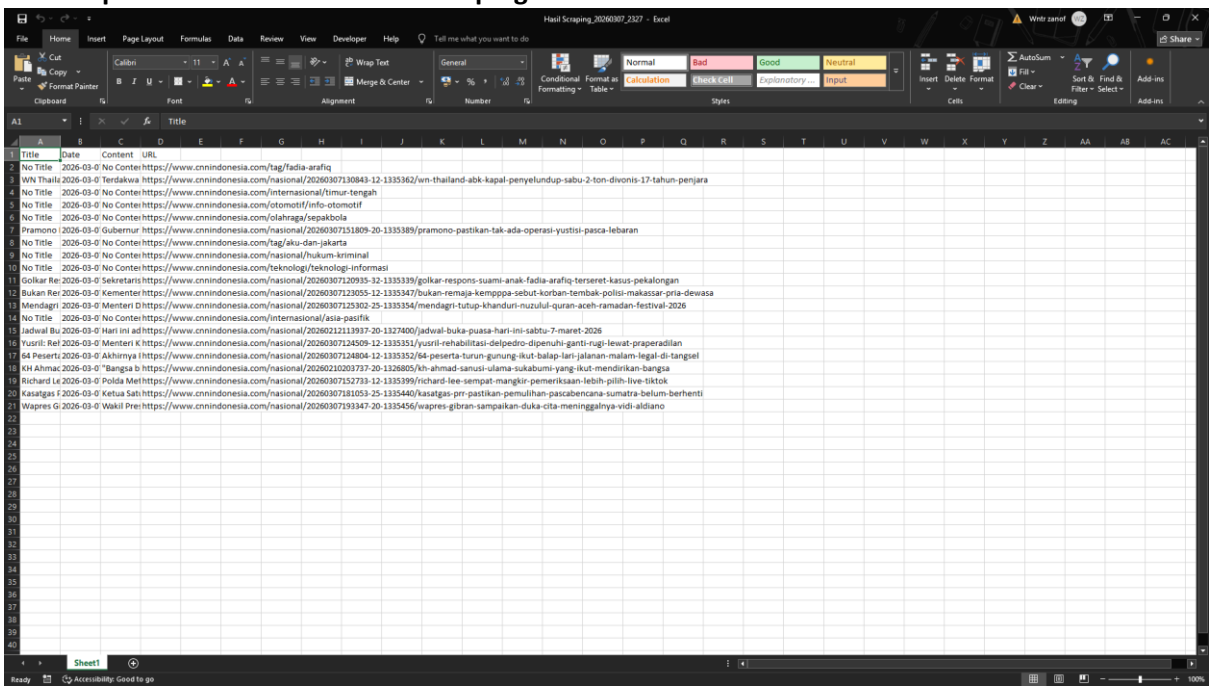
- **Tampilan File Excel berisi hasil Scraping**