NewsHarvest: Automated Scraping News

Pengenalan Tim

Proyek ini dibangun secara kolaboratif dengan pembagian tugas modular:

Kelompok C3, 1C, D4 Teknik Informatika

Nama Anggota	Tanggung Jawab Utama	Modul Terkait
Lunaraya Zenithra A. A. H	Pemrosesan Data & Utilitas Export	utils.py
Nesya Fadillah Kinantiasa	Engine scraping & automasi browser	scraper.py
Nurul Salmahat	Desain Antarmuka (GUI)	GUI.py
Umarwa Muhammad S. E	Arsitektur sistem & manajemen thread	main.py, worker.py

Deskripsi

Aplikasi ini dikembangkan sebagai sebuah sistem berbasis web yang berfungsi untuk melakukan pengambilan data berita secara otomatis dari portal berita di internet. Proses pengumpulan data dilakukan dengan teknik *web scraping*, di mana pengguna hanya perlu memasukkan alamat URL dari halaman berita yang ingin diambil informasinya. Selanjutnya, aplikasi akan mengakses setiap tautan artikel yang telah diperoleh untuk mengekstrak berbagai informasi penting yang terdapat pada halaman artikel. Informasi yang diambil meliputi judul berita, tanggal publikasi, isi berita, serta alamat URL artikel tersebut.

Data yang berhasil dikumpulkan akan ditampilkan pada antarmuka aplikasi sehingga pengguna dapat melihat hasil proses scraping secara langsung. Selain itu, sistem juga menyediakan fitur penyaringan data berdasarkan rentang tanggal tertentu agar pengguna dapat menyesuaikan data yang ingin ditampilkan sesuai dengan kebutuhan.

Sebagai tahap akhir, data yang telah diperoleh dapat disimpan atau diunduh dalam bentuk file dengan format CSV maupun Microsoft Excel. Fitur ini memungkinkan pengguna untuk memanfaatkan data tersebut lebih lanjut, seperti untuk keperluan analisis, pengolahan data, dokumentasi, maupun kegiatan penelitian.

Fitur Utama

1. Multithreading: Memungkinkan pengambilan data dalam jumlah banyak secara cepat tanpa menyebabkan aplikasi berhenti merespons (freeze).
2. Smart Link Filter: Logika penyaringan yang dapat membedakan antara artikel berita utama dengan tautan navigasi atau iklan.
3. Headless Mode: Kemampuan untuk menjalankan proses scraping di latar belakang tanpa memunculkan jendela browser di layar pengguna.
4. Modularitas: Kode disusun secara terpisah antar fungsi sehingga memudahkan proses pemeliharaan dan pengembangan lebih lanjut.

Spesifikasi & Persiapan

Sebelum menjalankan NewsHarvest, pastikan sistem ada memenuhi kriteria berikut:

1. Perangkat Lunak (Software)
   - Python: versi 3.6 atau lebih baru.
   - Browser: Google Chrome (Versi stabil terbaru sangat direkomendasikan).
   - Sistem Operasi: Windows 10/11
2. Pustaka Python
   Instalasi pustaka yang diperlukan dapat dilakukan melalui terminal:

   ```
   pip install selenium PyQt5 pandas openpyxl webdriver-manager
   ```

Prosedur Instalasi

1. Unduh Repositori
   Gunakan Git atau unduh file ZIP dari repositori ini

   ```
   git clone https://github.com/Lemonil0u/Week4_C3-Project1.git
   ```

2. Verifikasi / install semua library

   ```
   pip install -r requirements.txt
   ```

   atau install semua library secara manual:

   ```
   pip install selenium webdriver-manager PyQt5 openpyxl dateparser beautifulsoup4 newspaper3k
   ```

3. Eksekusi Program
   Jalankan file utama melalui terminal/command prompt:

   ```
   python main.py
   ```

Alur Kerja Aplikasi (Scraping Workflow)

1. Input Pengguna: Pengguna memasukkan URL target (seperti iNews atau CNN) dan menentukan batasan jumlah berita yang akan diambil melalui antarmuka.
2. Identifikasi Tautan: Mesin scraper akan memproses halaman utama URL tersebut untuk mendeteksi tautan berita yang relevan berdasarkan pola struktur URL.
3. Ekstraksi Data Paralel: Sistem membuka tautan berita yang ditemukan secara bersamaan menggunakan ThreadPoolExecutor untuk meningkatkan efisiensi waktu pengambilan data.
4. Pengolahan Konten: Data berupa judul, tanggal, dan isi berita diekstrak dan divalidasi guna memastikan informasi yang didapat sesuai dengan kebutuhan.
5. Penyajian & Ekspor: Hasil akhir ditampilkan secara real-time pada tabel aplikasi dan dapat disimpan ke dalam format file eksternal (Excel/CSV).

Panduan Penggunaan

1. Jalankan aplikasi melalui terminal/command prompt dengan perintah

   ```
   python main.py
   ```

2. Pada kolom input yang tersedia, masukkan alamat URL halaman berita yang ingin diambil datanya, misalnya: https://www.cnnindonesia.com/nasional

3. Lakukan pengaturan tambahan sesuai kebutuhan (opsional), antara lain:
   - **Limit artikel** — menentukan jumlah maksimum artikel yang akan diproses (isi `0` untuk mengambil seluruh artikel yang tersedia).
   - **Filter tanggal** — aktifkan opsi ini jika ingin membatasi artikel berdasarkan rentang tanggal tertentu.
   - **Max karakter konten** — mengatur jumlah karakter isi artikel yang akan ditampilkan.
4. Tekan tombol start untuk memulai proses scraping
5. Hasil artikel yang ditemukan akan ditampilkan secara bertahap pada tabel di aplikasi.
6. Proses dapat dihentikan kapan saja dengan menekan tombol Stop.

Panduan Mengekspor Data

1. Tunggu hingga proses scraping selesai, atau hentikan secara manual dengan tombol Stop.
2. Untuk menyimpan data dalam format CSV, klik tombol Export CSV.
3. Jika ingin menyimpan dalam format Excel, pilih tombol Export Excel.
4. Setelah itu, tentukan lokasi penyimpanan file melalui jendela dialog yang muncul.

#Dokumentasi Aplikasi

- Tampilan Scraping

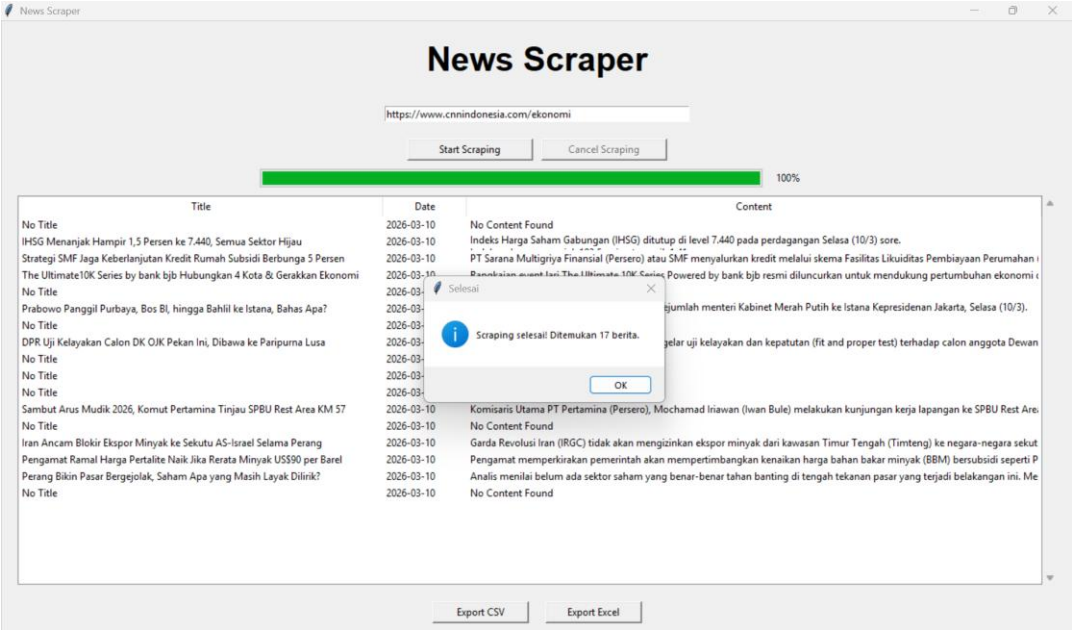

- Tampilan Export Excel

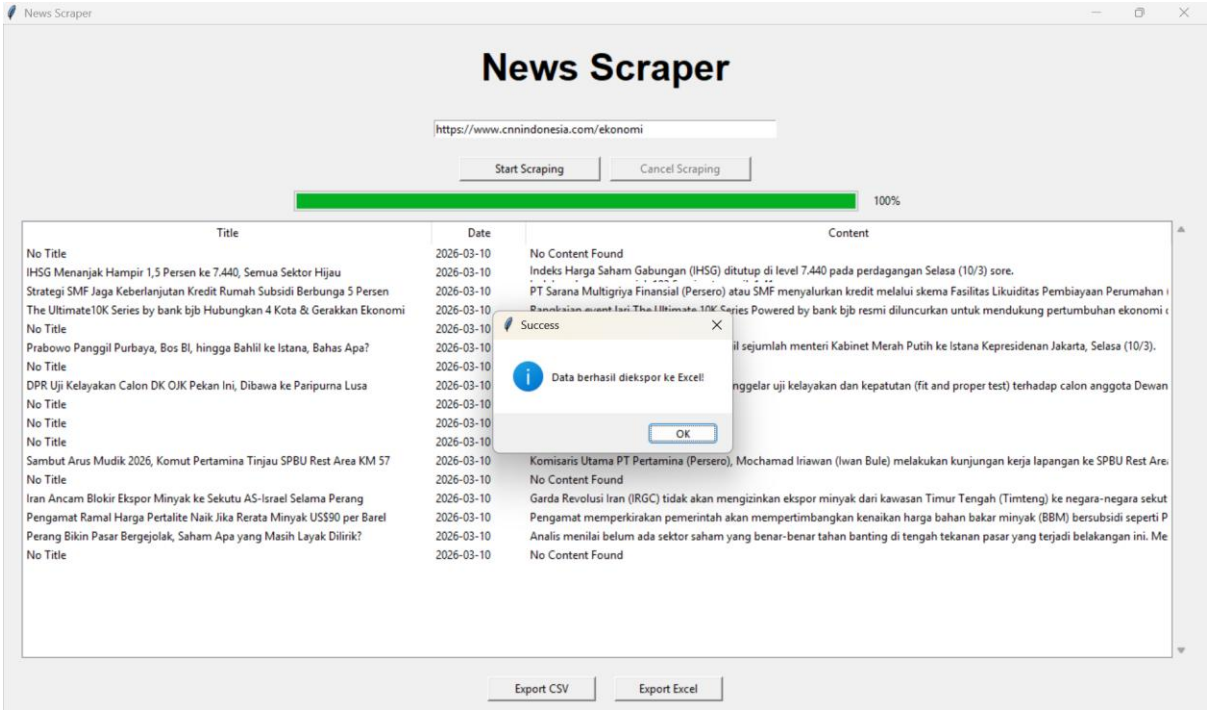

- Tampilan Export CSV

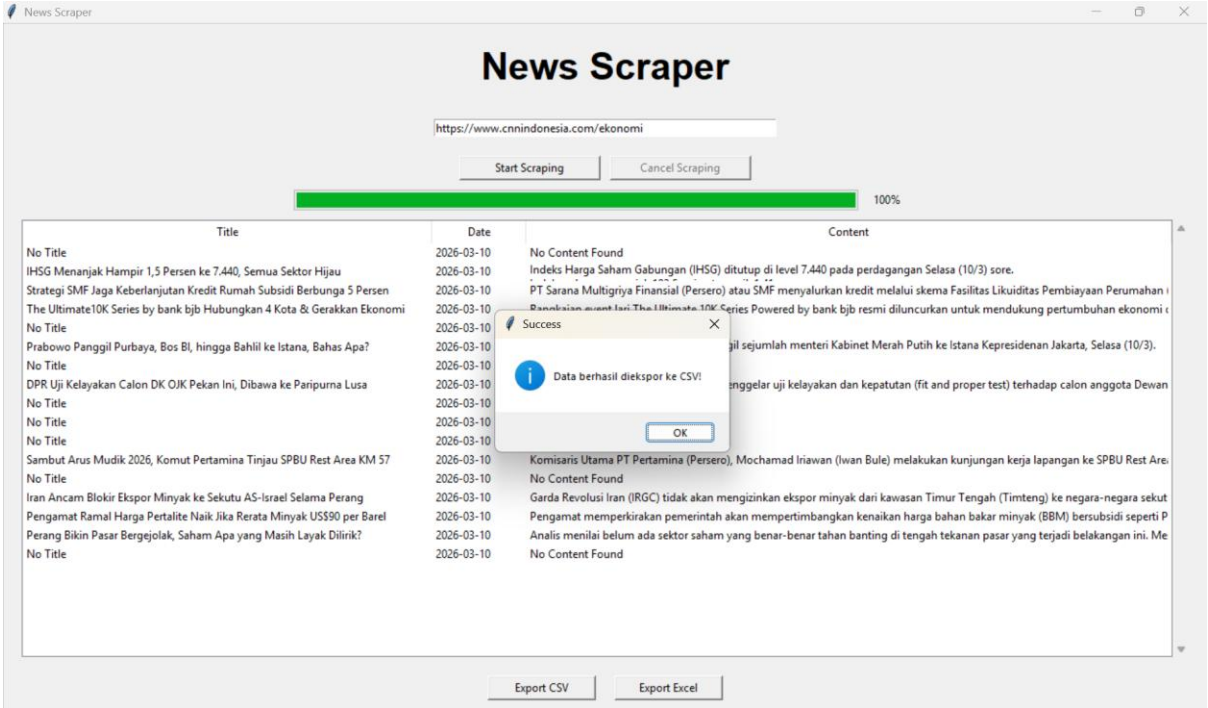

- Tampilan File Excel berisi hasil Scraping

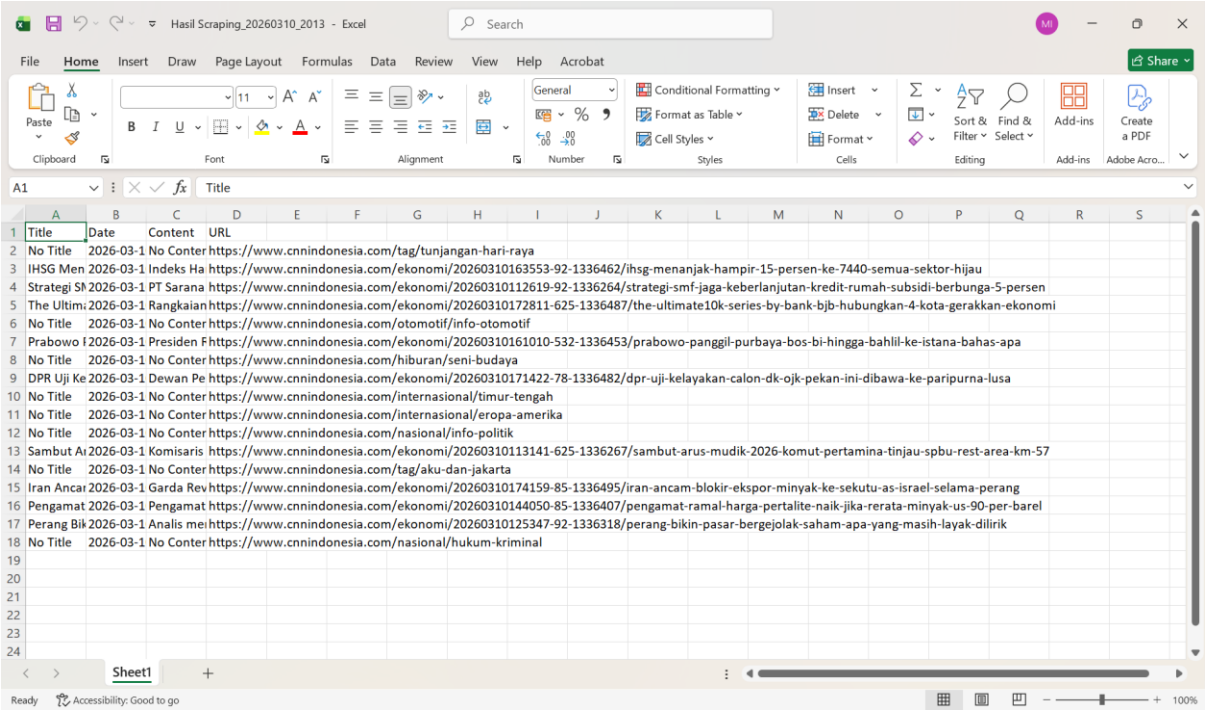

Title	Date	Content	URL
No Title	2026-03-1	No Conter	https://www.cnnindonesia.com/tag/tunjangan-hari-raya
IHSG Men	2026-03-1	Indeks Ha	https://www.cnnindonesia.com/ekonomi/20260310163553-92-1336462/ihsg-menanjak-hampir-15-persen-ke-7440-semua-sektor-hijau
Strategi Sh	2026-03-1	PT Sarana	https://www.cnnindonesia.com/ekonomi/20260310112619-92-1336264/strategi-smf-jaga-keberlanjutan-kredit-rumah-subsidi-berbunga-5-persen
The Ultim	2026-03-1	Rangkaian	https://www.cnnindonesia.com/ekonomi/20260310172811-625-1336487/the-ultimate10k-series-by-bank-bjb-hubungkan-4-kota-gerakkan-ekonomi
No Title	2026-03-1	No Conter	https://www.cnnindonesia.com/otomotif/info-otomotif
Prabowo I	2026-03-1	Presiden F	https://www.cnnindonesia.com/ekonomi/20260310161010-532-1336453/prabowo-panggil-purbaya-bos-bi-hingga-bahlil-ke-istana-bahas-apa
No Title	2026-03-1	No Conter	https://www.cnnindonesia.com/hiburan/seni-budaya
DPR Uji Ke	2026-03-1	Dewan Pe	https://www.cnnindonesia.com/ekonomi/20260310171422-78-1336482/dpr-uji-kelayakan-calon-dk-ojk-pekan-ini-dibawa-ke-paripurna-lusa
No Title	2026-03-1	No Conter	https://www.cnnindonesia.com/internasional/timur-tengah
No Title	2026-03-1	No Conter	https://www.cnnindonesia.com/internasional/eropa-amerika
No Title	2026-03-1	No Conter	https://www.cnnindonesia.com/nasional/info-politik
Sambut A	2026-03-1	Komisaris	https://www.cnnindonesia.com/ekonomi/20260310113141-625-1336267/sambut-arus-mudik-2026-komut-pertamina-tinjau-spbu-rest-area-km-57
No Title	2026-03-1	No Conter	https://www.cnnindonesia.com/tag/aku-dan-jakarta
Iran Ancar	2026-03-1	Garda Rev	https://www.cnnindonesia.com/ekonomi/20260310174159-85-1336495/iran-ancam-blokir-ekspor-minyak-ke-sekutu-as-israel-selama-perang
Pengamat	2026-03-1	Pengamat	https://www.cnnindonesia.com/ekonomi/20260310144050-85-1336407/pengamat-ramal-harga-pertalite-naik-jika-rerata-minyak-us-90-per-barel
Perang Bik	2026-03-1	Analis me	https://www.cnnindonesia.com/ekonomi/20260310125347-92-1336318/perang-bikin-pasar-bergejolak-saham-apa-yang-masih-layak-dilirik
No Title	2026-03-1	No Conter	https://www.cnnindonesia.com/nasional/hukum-kriminal